

LAPORAN DAN ANALISIS MACHINE LEARNING
Ch 3 Book Introduction to Machine Learning with Python : Unsupervised
Learning



Disusun Oleh :

Ludvie Pradya Paramitha Susaningtias

G1A024001

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU
2026

1. Pendahuluan

Laporan ini merangkum hasil analisis dari serangkaian eksperimen yang telah dijalankan pada *Book Introduction to Machine Learning with Python Chapter 3: Unsupervised Learning and Preprocessing*. *Unsupervised learning* adalah pendekatan pembelajaran mesin yang bekerja pada data tanpa label, dengan tujuan mengekstraksi struktur, pola, atau representasi tersembunyi dari data tersebut. Notebook ini mencakup tiga topik utama, yaitu: Preprocessing dan scaling data beserta pengaruhnya terhadap performa model supervised. Transformasi/reduksi dimensi data menggunakan Principal Component Analysis (PCA), Non-negative Matrix Factorization (NMF), dan t-SNE. Clustering menggunakan K-Means, Agglomerative (Hierarchical) Clustering, dan DBSCAN, termasuk evaluasi kualitas cluster. Dataset yang digunakan meliputi Breast Cancer Wisconsin (klasifikasi biner), Labeled Faces in the Wild / LFW Handwritten Digits, serta beberapa dataset sintetis

2. Preprocessing dan Scaling Data

2.1 MinMaxScaler pada Dataset Breast Cancer

Data dibagi menjadi training set sebanyak 426 sampel dan test set sebanyak 143 sampel, masing-masing dengan 30 fitur. Setelah fitting MinMaxScaler pada data training, seluruh fitur berhasil ditransformasi ke rentang $[0, 1]$ pada data training. Namun ketika scaler yang sama diterapkan pada data test, nilai minimum dan maksimumnya sedikit menyimpang dari $[0, 1]$ contohnya nilai maksimum pada beberapa fitur mencapai lebih dari 1 dan nilai minimum ada yang negatif. Ini adalah hasil yang benar dan diharapkan, karena scaler harus di-fit hanya pada data training agar tidak terjadi kebocoran informasi dari test set.

2.2 Dampak Scaling terhadap Performa SVM

Untuk mengevaluasi pentingnya scaling, model Support Vector Machine (SVC dengan $C=100$) dilatih pada data breast cancer dengan tiga kondisi berbeda:

Tabel 1. Hasil *scaling*


Kondisi Data	Akurasi Test Set
Tanpa scaling (data mentah)	0.94
Setelah MinMaxScaler (skala 0–1)	0.97
Setelah StandardScaler (mean 0, variansi 1)	0.96

Hasil ini menunjukkan bahwa scaling fitur memberikan peningkatan akurasi yang cukup signifikan pada algoritma SVM, dari 94% menjadi 96–97%. Hal ini terjadi karena SVM sensitif terhadap skala fitur dengan rentang nilai besar dapat mendominasi perhitungan jarak jika tidak dinormalisasi terlebih dahulu.

3. Reduksi Dimensi dengan PCA


3.1 PCA pada Dataset Breast Cancer

Setelah data distandarisasi dengan StandardScaler, PCA diterapkan untuk mereduksi 30 fitur asli menjadi 2 komponen utama (dari shape (569, 30) menjadi (569, 2)). Visualisasi hasil proyeksi pada dua komponen utama menunjukkan bahwa kelas malignant dan benign dapat dipisahkan cukup baik hanya dengan dua komponen, meskipun terdapat sedikit overlap di area perbatasan.



Gambar 1. Sebaran data breast cancer pada dua komponen utama PCA (malignant vs benign).

Heatmap koefisien dari dua komponen utama terhadap 30 fitur asli memperlihatkan bahwa komponen pertama merupakan kombinasi hampir seluruh fitur dengan bobot searah (mewakili ukuran/keganasan tumor secara umum), sedangkan komponen kedua membedakan fitur-fitur berdasarkan tekstur dan bentuk secara lebih spesifik.



Gambar 2. Heatmap kontribusi (loading) tiap fitur terhadap komponen utama pertama dan kedua.

3.2 PCA pada Dataset Wajah (LFW People)

Dataset LFW berisi 3.023 citra wajah dari 62 orang berbeda. Sebagai baseline, klasifikasi 1-Nearest Neighbor langsung pada data piksel mentah hanya mencapai akurasi 22% pada test set menunjukkan bahwa data piksel mentah berdimensi tinggi kurang informatif secara langsung untuk klasifikasi wajah. Dengan menerapkan PCA whitening, performa 1-NN meningkat menjadi 30%. Meskipun kenaikannya tidak drastis, hasil ini mengonfirmasi bahwa reduksi dimensi dengan PCA dapat membantu mengekstrak representasi yang lebih relevan dibanding piksel mentah, sekaligus jauh mengurangi dimensi data. Visualisasi komponen utama menunjukkan pola wajah umum pada komponen-komponen awal, sedangkan rekonstruksi citra dengan jumlah komponen berbeda memperlihatkan bahwa semakin banyak komponen yang digunakan, semakin detail dan mirip hasil rekonstruksi dengan citra aslinya.

4. Non-negative Matrix Factorization (NMF)

NMF diterapkan pada dataset wajah dengan 15 komponen. Berbeda dengan PCA yang komponennya dapat bernilai negatif dan bersifat ortogonal, komponen NMF bersifat non-negatif sehingga masing-masing komponen cenderung merepresentasikan bagian wajah tertentu secara aditif.



Gambar 3. Lima belas komponen NMF yang diekstraksi dari data wajah.


Dengan mengurutkan citra berdasarkan bobot komponen tertentu, terlihat bahwa citra dengan bobot tertinggi pada komponen tersebut memiliki karakteristik visual yang konsisten, menunjukkan bahwa NMF berhasil menangkap pola-pola bermakna secara aditif.

4.1 Pemisahan Sinyal Campuran (Signal Unmixing)

Pada eksperimen sintesis dengan tiga sinyal sumber yang dicampur menjadi 100 sinyal hasil pengukuran, NMF berhasil merekonstruksi kembali bentuk sinyal sumber dengan cukup baik. Sebagai pembandingan, PCA juga dicoba pada data yang sama namun hasilnya kurang menyerupai sinyal sumber asli dibanding NMF, karena PCA mencari arah varians maksimum, sehingga kurang cocok untuk kasus pemisahan sinyal seperti ini.

5. Manifold Learning dengan t-SNE

Pada dataset handwritten digits, perbandingan dilakukan antara proyeksi dan t-SNE. Hasil visualisasi menunjukkan bahwa PCA menghasilkan pengelompokan antar-kelas yang masih banyak bertumpang tindih, sedangkan t-SNE menghasilkan pemisahan antar-kelas digit yang jauh lebih jelas dan rapat dalam cluster masing-masing angka.




Gambar 4. Proyeksi t-SNE dataset digits — setiap warna/angka membentuk kelompok yang terpisah jelas.

Hal ini sesuai dengan karakteristik t-SNE yang dirancang khusus untuk visualisasi struktur lokal data berdimensi tinggi ke ruang 2D, meskipun perlu diperhatikan bahwa t-SNE tidak memiliki method transform() sehingga tidak dapat langsung diterapkan pada data baru (harus fit_transform ulang).

6. Clustering

6.1 K-Means

K-Means diuji pada data sintetis dengan berbagai jumlah cluster. Pada kasus dengan 3 cluster yang well-separated, K-Means berhasil mengelompokkan data dengan baik sesuai bentuk aslinya.




Gambar 5. Hasil clustering K-Means ($k=3$) pada data blobs sintetis; segitiga menandakan centroid.

Namun pada kasus data dengan varians cluster yang tidak seragam, data yang diregangkan secara linear, dan data berbentuk non-konveks seperti two-moons, K-Means menunjukkan keterbatasan yang jelas algoritma ini cenderung membagi cluster secara membulat dan gagal mengenali bentuk cluster yang memanjang atau berbentuk bulan sabit, karena K-Means hanya memperhitungkan jarak ke centroid.

6.2 Agglomerative (Hierarchical) Clustering


Agglomerative clustering dengan linkage ward diuji pada data blobs dan menghasilkan pembagian cluster yang menyerupai hasil K-Means. Visualisasi dendrogram membantu menentukan jumlah cluster optimal secara visual berdasarkan jarak pada contoh 12 titik data, dendrogram jelas menunjukkan titik potong untuk 2 maupun 3 cluster.



Gambar 6. Dendrogram hasil agglomerative clustering (ward linkage) pada 12 titik data sintetis.

6.3 DBSCAN

DBSCAN dengan parameter default pada 12 titik data blobs menghasilkan seluruh titik diklasifikasikan sebagai noise, menunjukkan sensitivitas tinggi DBSCAN terhadap parameter ϵ dan min_samples yang perlu disesuaikan dengan skala data. Pada data two-moons yang telah distandarisasi, DBSCAN dengan parameter default berhasil memisahkan dua bulan sabit dengan baik sesuatu yang tidak dapat dilakukan K-Means maupun agglomerative clustering karena bentuk clusternya non-konveks.



Gambar 7. DBSCAN berhasil memisahkan dua cluster berbentuk bulan sabit (two-moons).

7. Evaluasi Kualitas Clustering

Dua metrik evaluasi digunakan: Adjusted Rand Index (ARI) memerlukan label ground truth dan Silhouette Score, yang tidak memerlukan label. Eksperimen sederhana menunjukkan perbedaan penting antara accuracy dan ARI: dua labeling cluster yang secara substansi identik namun penomoran labelnya tertukar menghasilkan accuracy 0.00 namun ARI 1.00, karena ARI tidak bergantung pada penamaan/urutan label melainkan pada kesamaan struktur pengelompokan.

Pada perbandingan tiga algoritma terhadap data two-moons menggunakan ground truth, DBSCAN memperoleh ARI tertinggi karena mampu menangkap bentuk cluster non-konveks, sedangkan K-Means dan agglomerative clustering mendapat skor ARI yang jauh lebih rendah pada kasus ini akibat asumsi bentuk cluster yang bulat.

8. Studi Kasus: Ekstraksi Cluster pada Data Wajah (LFW)

Sebagai studi kasus terapan, data wajah dianalisis menggunakan ketiga algoritma clustering:

8.1 DBSCAN pada Data Wajah

Dengan parameter default, DBSCAN gagal menemukan cluster. Setelah `min_samples` diturunkan menjadi 3 dan `eps` ditingkatkan bertahap, baru pada `eps=7` DBSCAN mulai menemukan cluster kecil. Pada `eps=11` hanya tersisa 1 cluster besar dan noise. Hasil ini menegaskan bahwa DBSCAN kurang cocok untuk data berdimensi tinggi dan tersebar seperti data wajah, karena kepadatan titik yang bervariasi menyulitkan pemilihan parameter `eps` yang tepat untuk seluruh dataset.

8.2 K-Means pada Data Wajah


K-Means dengan `k=10` menghasilkan ukuran cluster yang relatif seimbang. Visualisasi centroid cluster menampilkan wajah rata-rata yang cukup jelas untuk tiap cluster, meskipun anggota dalam satu cluster tidak selalu berasal dari orang yang sama. K-Means lebih mengelompokkan berdasarkan kemiripan visual umum dibanding identitas orang.



Gambar 8. Centroid dari 10 cluster K-Means pada data wajah, direkonstruksi dari ruang PCA.

8.3 Agglomerative Clustering pada Data Wajah

Dengan 10 cluster, agglomerative clustering menghasilkan distribusi ukuran cluster yang lebih tidak merata dibanding K-Means. Nilai ARI antara hasil agglomerative dan K-Means hanya 0.08, menunjukkan bahwa kedua algoritma menghasilkan pengelompokan yang cukup berbeda satu sama lain pada data ini wajar mengingat perbedaan mendasar cara kerja keduanya.



Gambar 9. Dendrogram (terpotong) hasil agglomerative clustering pada data wajah.

Ketika jumlah cluster diperbesar menjadi 40, beberapa cluster yang dihasilkan justru berhasil mengelompokkan wajah dari orang yang sama dengan cukup konsisten, menunjukkan bahwa dengan granularitas lebih tinggi, agglomerative clustering dapat menangkap kemiripan identitas meskipun tetap tidak sepenuhnya identik dengan pengelompokan berdasarkan label asli.

Kesimpulan

Berdasarkan seluruh eksperimen yang telah dijalankan, dapat disimpulkan beberapa hal berikut:

1. Scaling fitur MinMaxScaler atau StandardScaler terbukti penting untuk algoritma yang sensitif terhadap skala seperti SVM, meningkatkan akurasi dari 94% menjadi 96–97% pada dataset breast cancer.
2. PCA efektif untuk reduksi dimensi dan visualisasi data berdimensi tinggi, namun peningkatan performa klasifikasi yang diberikannya bergantung pada karakteristik data
3. NMF lebih unggul dibanding PCA untuk kasus yang membutuhkan komponen non-negatif dan aditif, seperti pemisahan sinyal campuran maupun ekstraksi pola wajah yang bermakna secara fisik.
4. t-SNE unggul dalam memvisualisasikan struktur cluster/kelas pada data berdimensi tinggi dibanding PCA, meskipun tidak dapat digunakan untuk mentransformasi data baru.
5. Ketiga algoritma clustering memiliki kelebihan dan keterbatasan berbeda: K-Means dan Agglomerative bekerja baik pada cluster berbentuk konveks/bulat, sedangkan DBSCAN unggul pada cluster non-konveks namun sangat sensitif terhadap pemilihan parameter eps dan min_samples, khususnya pada data berdimensi tinggi seperti citra wajah.
6. Evaluasi clustering sebaiknya menggunakan metrik seperti Adjusted Rand Index alih-alih accuracy biasa, karena ARI tidak terpengaruh oleh permutasi penomoran label cluster.